

基于 GAN 样本生成技术的智能诊断方法

马 波^{1,2,3}, 蔡伟东¹, 赵大力⁴

(1. 北京化工大学 机电工程学院, 北京 100029;

2. 北京化工大学 高端机械装备健康监控及自愈化北京市重点实验室, 北京 100029;

3. 北京化工大学 发动机健康监控及网络化教育部重点实验室, 北京 100029;

4. 北京博华信智科技股份有限公司, 北京 100029)

摘 要: 基于数据驱动的设备故障智能诊断方法是监测设备健康状况的重要手段,然而实际应用中,难以获取到足量有效的故障数据训练智能诊断模型。鉴于设备健康状态数据充足和现有智能诊断方法故障机理利用不足,提出基于生成对抗网络(GAN)样本生成技术的智能诊断方法。健康状态数据反映了设备个性特征,故障机理反映了设备共性特征,基于两种特征融合,得到故障数据样本,通过对深度卷积神经网络的训练为设备个体构建个性化的智能诊断模型。采用来自 CWRU 轴承数据和实验台模拟故障数据进行的实验结果表明,该方法相比现有智能诊断方法无需真实故障样本,在变负载条件下实现了很高的诊断准确率,具有较好的变工况迁移能力。

关键词: 生成对抗网络(GAN);样本生成;故障机理;智能诊断;迁移学习

中图分类号: TH17;TP277

文献标志码: A

DOI:10.13465/j.cnki.jvs.2020.18.020

Intelligent diagnosis method based on GAN sample generation technology

MA Bo^{1,2,3}, CAI Weidong¹, ZHAO Dali⁴

(1. College of Mechanical and Electrical Engineering, Beijing University of Chemical Technology, Beijing 100029, China;

2. Beijing Key Laboratory of Healthy Monitoring Control and Fault Self-Recovery for High-end Machinery,

Beijing University of Chemical Technology, Beijing 100029, China; 3. Key Laboratory of Engine Health Monitoring and Networking

Ministry of Education, Beijing University of Chemical Technology, Beijing 100029, China;

4. Beijing Bohua Xinzhi Technology Co., Ltd., Beijing 100029, China)

Abstract: Intelligent fault diagnosis based on data-driven is an important tool to monitor the health of equipments. However, in practical applications, it is difficult to obtain a sufficiently effective intelligent diagnosis model for fault data training. In view of an abundance of available equipment health status date and yet the underutilization of existing intelligent diagnosis methods, an intelligent diagnosis method based on GAN (generative adversarial networks) sample generation technology was proposed. The health status data reflects the characteristic features of the device, and the knowledge of the fault mechanism reflects the common features of the device. Fusing the two features, fault samples were obtained. By training the deep convolutional neural network, a diagnostic model was constructed for each device in order to realize the fault diagnosis under different working conditions. The test results from the CWRU bearing data and the simulated fault data on a test bench show that the proposed method can achieve high diagnostic accuracy under variable load conditions and has good working condition transfer ability.

Key words: generative adversarial networks (GAN); sample generation; fault mechanism; intelligent diagnosis; transfer learning

随着工业 4.0 和“智能+”的提出,设备健康监测进入大数据时代^[1-2],基于数据驱动和深度学习的设

备故障智能诊断方法成为研究热点。例如,文献[3]运用卷积神经网络(Convolutional Neural Network, CNN)构建特征自学习模型实现了对旋转机械系统的故障诊断;文献[4]采用优化的深度信念网络提高了轴承故障诊断模型的泛化性能;文献[5]提出的堆栈降噪自编码在齿轮的状态识别上取得了较大成功。相比传统基于

基金项目: 国家重点研发计划(2016YFF0203305)

收稿日期: 2019-03-25 修改稿收到日期: 2019-07-02

第一作者 马波 男,博士,副研究员,1977 年生

信号处理的诊断方法,智能诊断方法通过对大量监测数据的学习能自动识别设备状态,可减轻对专业诊断人员的依赖。

然而现有的智能诊断方法大都建立在数据样本充足的情况下,将其应用于工程实际存在故障数据稀缺的问题:在一台设备的全生命周期内故障数据屈指可数,甚至有些故障从未发生,且设备制造安装误差等个体差异^[6-7]以及运行工况变化使得设备应用场景复杂多变,不同设备个体的故障数据难以共用,造成样本空间的完备性无法保证^[8]。针对此问题,文献[9]通过有限元方法建立机械故障仿真模型,利用仿真数据训练诊断模型,但该方法脱离真实的设备个体,忽略了实际场景中设备个体差异对诊断的干扰,使得实际应用中诊断精度不高。为解决智能诊断方法在工程应用中受数据规模限制的问题,近年来,基于迁移学习理论的方法受到研究人员的关注,该方法将源领域的故障诊断知识迁移到另一目标领域,源领域与目标领域可以是不同的工况也可以是不同的设备个体。陈超等基于辅助数据集的迁移学习方法对轴承进行故障诊断,提高了变工况条件下轴承故障诊断的准确率;文献[10]通过最小化源领域与目标领域间的 Wasserstein 距离学习得到两领域间的共享特征,实现不同工况下特征提取方法的迁移;文献[11]利用不同设备的监测数据构建领域共享的深度残差网络提取迁移故障特征,运用实验室轴承数据训练的诊断模型识别出机车轴承的健康状况。以上方法能解决训练样本不足的问题,但仍以源领域的数据充足为前提,且难以解释迁移特征的直观意义。

针对以上不足,本文考虑到实际应用中健康状态数据充足,故障机理较为清晰,若能充分挖掘健康状态数据中的有效信息,同时将可解释性很强的故障机理融入诊断模型之中,则有望实现智能诊断方法的研究成果向工程应用转化。文献[12]指出智能诊断方法应建立在故障机理等底层基础研究之上,单纯借助人工智能方法难以解决实际工程问题,据此,文献[13]利用信号处理方法选择并提取合适的特征实现了基于特征迁移的变工况下滚动轴承故障诊断,使得迁移特征有了实际物理意义;文献[14]基于专家思维模式构建故障矩阵和权重矩阵,保证了诊断的准确性;文献[15]提出引导学习的理论方法,将专业知识和经验内嵌到机器学习指导电力系统的稳定运行;此外,文献[16]运用 GAN(Generative Adversarial Networks)技术将数据与机理结合,解决能源系统中的模型切换问题。GAN 已经在机器统计学习最为活跃的图像识别领域取得了很好的表现,有研究表明^[17-18],其对改善模型训练效果,克服样本不足有着促进作用,在设备故障诊断领域,基于 GAN 的应用更多侧重于源领域与目标领域间对抗

训练^[19],而基于 GAN 生成数据样本训练诊断模型的研究尚不多。

综上分析,现有研究者更多通过网络结构、训练方式的改进获取迁移特征,一方面对故障机理利用不足;另一方面忽略了设备个体差异所体现的个性特征对诊断准确率的提升作用。而故障机理是价值含量极高的隐形数据,设备健康状态数据包含了该台设备的个性特征信息,因此本文将故障机理和个性特征结合,以设备健康状态数据为基础,通过故障机理选择迁移特征,提出一种基于 GAN 理论的机理-个性生成模型(Mechanism Character Generative Model, MCGM)方法,利用 MCGM 得到的样本训练诊断模型,为每个个体单独建立不依赖于真实故障样本的智能诊断模型,最后采用滚动轴承数据对提出方法进行验证。

1 理论背景

1.1 GAN 理论

GAN 是 Goodfellow 等^[20]受博弈论启发提出的一种生成模型,它由一个生成器 G 和一个判别器 D 构成。 G 学习真实数据的分布规律,以此生成新样本; D 是分类器,用来判别输入是真实数据还是生成样本, G 和 D 之间通过对抗学习彼此不断提升,当 D 无法判断输入来源时,可认为 G 学习到了真实数据的分布。

在 GAN 的训练中,将采样于真实数据分布 $p_{data(x)}$ 的样本 x 标注为 1, G 生成的数据分布 $p_{z(z)}$ 的样本标注为 0, $D(x)$ 代表 x 来源于真实数据的概率。当输入为 x , D 的目标是使 $D(x)$ 趋近于 1,而当输入为 $G(z)$,则应使 $D(G(z))$ 趋近于 0,但此时 G 的目标是使其趋近于 1。这实际上是 G 和 D 间的对抗博弈,所以 GAN 的训练是一个极小极大化问题,其目标函数可描述为

$$\min_G \max_D \{f(D, G) = E_{x \sim p_{data(x)}} [\log D(x)] + E_{z \sim p_{z(z)}} [\log(1 - D(G(z)))]\} \quad (1)$$

式中: z 为先验分布,如高斯分布、均匀分布; E 为计算期望值。因此,GAN 的训练过程包含 G 的学习和 D 的优化,通常采用两者交替的方法,即先固定 G ,优化 D ,使得 D 的判别准确率最大化;然后固定 D ,训练 G ,使得 D 的判别准确率最小化。

深度卷积生成对抗网络是由 Facebook AI 研究员提出的一种 GAN 改进结构^[21]。其将 G 和 D 中均设计为 CNN 结构,以此来提高 GAN 的效果。但依据随机变量 z 作为输入,往往使得生成效果不稳定,且缺乏实际意义,未能充分利用已有信息,Mirza 等^[22]提出将 z 连同条件变量 c 作为输入,用于指导数据生成过程。基于此,本文采用条件深度卷积生成对抗网络(Conditional-Deep Convolutional Generative Adversarial Networks, c-DCGAN)用于数据生成,图 1 为 c-DCGAN 基本结构和

计算流程。




图 1 c-DCGAN 基本结构和计算流程

Fig. 1 Basic structure and computation procedure of c-DCGAN

2 基于 MCGM 的智能诊断方法

本文提出的基于 MCGM 的智能诊断方法包括样本生成和诊断模型构建两阶段。首先采用 MCGM 方法生成训练样本,然后构建基于深度 CNN 的诊断模型。

2.1 MCGM 原理

在机器视觉的物体检测中,常将图像分为背景与前景,通过对背景噪声的过滤实现前景物体的定位,借鉴于此,对于任一系统状态,都可描述为背景与前景的叠加,背景提供该系统区别于其他系统的个性特征信息,前景提供该系统所处的状态信息。将其应用于机械振动系统,某设备的故障状态由个性特征与故障特征组成,故障特征可由故障机理获取,个性特征则与具体设备个体有关,对基于传感器采集的信号进行状态描述的系统而言,由于传感器安装位置等的限制,对某一零部件的监测信号中存在许多未知干扰,例如测量系统误差、周围零部件的振动等,这些干扰信号不随待监测零部件状态的变化而变化或变化很小,因此可将健康状态作为设备个性特征的描述。

综上所述,本文提出的基于 MCGM 的样本生成方法,其原理如图 2 所示。具体步骤如下:

- 步骤 1 对待研究设备故障机理 M 进行分析确定迁移特征,掌握各类故障下迁移特征变化规律,建立基于该规律的迁移特征集 H 。
- 步骤 2 基于具体设备的健康状态数据 x ,以运行工况信息 c 作为 c-DCGAN 的条件,对设备个性特征空间 G_{char} 重构。
- 步骤 3 将采样于 G_{char} 的虚拟健康状态数据样本与 H 运算,得到该设备各类虚拟故障的数据样本,并与 x 合并形成训练样本。




图 2 MCGM 原理图

Fig. 2 An overview of the MCGM methodology

2.2 样本生成

基于 MCGM 原理,样本生成可分为迁移特征选择与提取、个性特征空间重构和训练样本生成三大流程。

2.2.1 迁移特征选择与提取

故障状态是一类模糊系统,无法用公式、函数准确表示,但可依据故障机理分析其主要特征,通过特征间的相互限定,表达出能切合实际的故障状态。具体步骤如下:

步骤 1 依据故障机理、诊断工程师等提供的相关知识、经验,确定可应用于对设备进行诊断的有效特征向量作为迁移特征

$$F_{ea} = \{f_{ea_{11}}, f_{ea_{12}}, \cdots, f_{ea_{1j}}, \cdots, f_{ea_{1m}}\}$$

式中, $f_{ea_{1j}}$ 为 m 维迁移特征 $f_{ea_{1}}$ 的第 j 个特征分量,迁移特征亦可为 $f_{ea_{1}}$ 等多种特征的集合。

步骤 2 提取设备监测数据的迁移特征。常见的特征提取方法有时域分析、频域分析以及时频域分析。

步骤 3 已知设备有 n 类故障

$$F_{au} = \{f_{au_{11}}, f_{au_{12}}, \cdots, f_{au_{1i}}, \cdots, f_{au_{1n}}\}$$

依据各故障的机理,确定各类故障下 F_{ea} 的变化规律,将变化情况转换为数学模型描述

$$H = \begin{bmatrix} h_{1-1} & h_{1-2} & \cdots & h_{1-m} \\ \cdots & \cdots & \cdots & \cdots \\ h_{i-1} & h_{i-j} & \cdots & h_{i-m} \\ \cdots & \cdots & \cdots & \cdots \\ h_{n-1} & h_{n-2} & \cdots & h_{n-m} \end{bmatrix} \quad (2)$$

式中, h_{i-j} 为发生故障 $f_{au_{1i}}$ 时特征分量 $f_{ea_{1j}}$ 变化情况的数学表达。

2.2.2 个性特征空间重构

随机变量 z 和工况参数 c 级联作为 G_{char} 的输入,经反卷积和激活函数输出 $G_{\text{char}}(z+c)$; 将 $G_{\text{char}}(z+c)$ 和 x 随机输入 D ,经多层的卷积层、池化层以及 BN 操作判断输入数据是 x 还是由 G_{char} 生成的虚假数据。采用式 (2) 的目标函数,循环训练 G_{char} 和 D ,每训练一次 D 更新 k 次 G_{char} ,如图 3 所示为 G_{char} 重构流程。

在 GAN 的训练中,生成器存在梯度消失的问题,这是由于判别器与生成器训练不平衡,导致判别器的判别性能很好而生成器无法生成逼真的数据。因此在训练过程中,每更新一次判别器,训练 k 次生成器,在本文一维振动数据的生成中, k 取 4 ~ 10 较为合适。表 1 为图 3 各网络参数,图 4 为生成的时域和频域数据与真实数据的对比。从图 4 可知, G_{char} 有效学习到数据的分布规律。重构的目的在于:学习设备监测数据的分布特征,使得不仅有真实样本,还有源源不断的生成样本,起到数据增强的作用;设备运行工况复杂多变,采用工况信息为条件以适应不同的工况。




图3 个性特征空间重构流程

Fig. 3 Flow chart of reconstructing character space of equipment

表1 c-DCGAN 网络参数

Tab.1 Parameters of c-DCGAN					
网络模块	层名称	大小	深度	激活函数	是否 BN
生成器	输入	100 + c	—	—	—
	全连接#1	32 768	1	ReLU	否
	Reshape	512	256	ReLU	否
	反卷积#1	256	128	ReLU	否
	反卷积#2	512	64	ReLU	否
	反卷积#3	2 048	1	tanh	否
判别器	卷积#1	5	64	ReLU	是
	池化#1	2	—	—	—
	卷积#2	5	128	ReLU	是
	池化#2	2	—	—	—
	卷积#3	3	256	ReLU	是
	池化#3	2	—	—	—
	全连接#2	n + 1	—	—	—

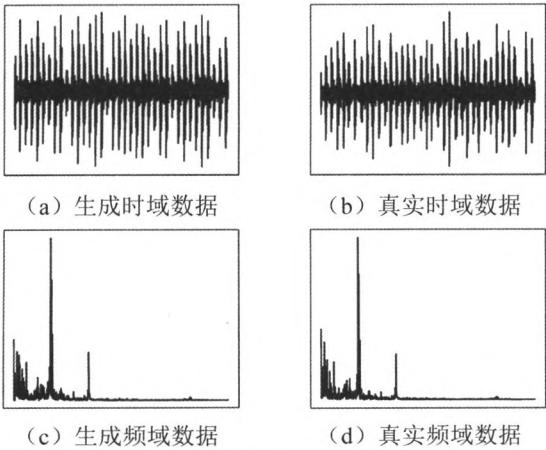


图4 生成数据与真实数据对比

Fig. 4 Comparison of generated data and real data

2.2.3 训练样本生成

训练样本的组成有两类:①真实样本,比如可大量获取的健康状态数据样本,试车期间的少量故障数据样本等;②生成的虚拟样本,其中虚拟故障数据样本的生成表示为

$$G_{\text{faut}} = H \times G_{\text{char}}(z + c)$$
 (3)

将采样于 G_{char} 的虚拟健康状态数据与真实健康状态数据混合作为训练样本中的健康状态数据,对 G_{faut} 采样得到设备 n 种故障状态数据样本,由此形成 $n + 1$ 种状态数据作为训练样本。对 G_{faut} 和 G_{char} 的采样结果应使每种状态的样本数量一致。

2.3 诊断模型构建

诊断模型结构如图 5 所示。将预处理后的监测数据作为故障分类器的输入,故障分类器是基于 Lenet-5 结构的一维 CNN 模型,包含 4 个交替连接的卷积层和池化层、2 个全连接层,其中第 2 个全连接层有 $n + 1$ 个神经元,预测输入属于每一类状态的概率,故障分类器最后经 Softmax 输出概率最大的状态为诊断结论,其详细的网络参数如表 2 所示。

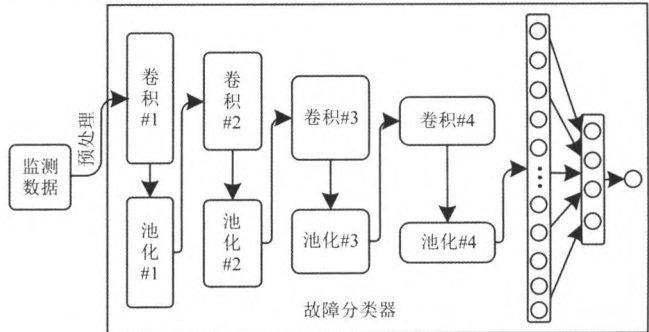


图5 诊断模型结构

Fig. 5 Structure of diagnostic model

表2 故障分类器参数

Tab.2 Parameters of CNN					
层名称	大小	深度	是否 BN	是否 Drop out	
卷积#1	20	64	是	否	
池化#1	2	—	否	否	
卷积#2	3	128	是	否	
池化#2	2	—	否	否	
卷积#3	3	192	是	否	
池化#3	2	—	否	否	
卷积#4	3	256	是	否	
池化#4	2	—	是	否	
全连接#1	1 024	—	否	是	
全连接#2	n + 1	—	否	否	

本文诊断模型的搭建和训练采用 Tensorflow 1.8。以交叉熵损失作为目标函数,将初始学习率设为 0.001、批大小为 32 作为训练参数训练故障分类器。当目标函数值趋于平稳时完成训练,诊断模型即可应用于诊断。

3 应用与分析

本文以滚动轴承的故障诊断为例,分别采用来自凯斯西储大学(CWRU)轴承数据中心的振动数据和搭建实验台模拟的故障数据两种实验数据对本文方法进行应用与分析,并与 Li 等和刘海宁等所提出方法进行对比。CWRU 轴承数据已成为设备故障诊断领域的标准数据集,被广泛用来比较各类算法的应用效果,本部分将重点对其进行分析。

3.1 实验数据

CWRU 轴承实验靠近电机的驱动端采用 SKF 生产的 6205 深沟球轴承,分别模拟了驱动端轴承在不同状态下的工作状况,其中每种状态分别进行 0 ~ 2.237 1 kW 4 种负载测试,通过安装在轴承座上的加速度传感器采集振动信号,采样频率 12 kHz,理论故障频率等参数及数据编号见表 3,其中故障尺寸 0 为健康状态数据。关于此数据集的更多说明可参见文献[23]。

表 3 CWRU 轴承数据参数及编号

Tab.3 Parameters and number for bearing data of CWRU				
故障尺寸/mm	负载/kW	内圈故障(IR)	外圈故障(OR)	滚动体故障(B)
0	0~2.237 1 kW	N_0~N_3		
0.177 8	0~2.237 1 kW	IR07_0~IR07_3	OR07_0~OR07_3	B07_0~B07_3
0.355 6	0~2.237 1 kW	IR14_0~IR14_3	OR14_0~OR14_3	B14_0~B14_3
0.533 4	0~2.237 1 kW	IR21_0~IR21_3	OR21_0~OR21_3	B21_0~B21_3
故障频率/Hz	0	162.19	107.36	141.17

为进一步验证本文方法的有效性,搭建如图 6 所示实验台,进行模拟轴承故障实验。实验台由调速电机、传动部分以及支撑轴承等组成,滚动轴承型号为 N205EM,2 个加速度传感器磁吸固定于轴承座上,采样频率 25 kHz。在一定转速下,人为制造轴承内、外圈故障,分别采集健康、内圈故障、外圈故障 3 种状态下的数据,采用 2 号传感器数据进行应用验证,更多实验数据参数列于表 4。




图 6 轴承故障模拟实验台
Fig.6 Test bench for simulation fault of bearings

表 4 实验台模拟故障数据参数

Tab.4 Parameters of test bench's simulated fault data			
系统状态	转速/(r·min ⁻¹)	样本数量	理论故障频率/Hz
健康	1 200	276	—
内圈故障	1 200	328	155.32
外圈故障	1 200	362	96.62

万方数据

3.2 方法应用

3.2.1 滚动轴承故障样本生成

(1) 迁移特征选择与提取

频谱分析是旋转设备最有效的诊断方法,诊断专家通过对频谱的观察推断设备故障,其原理是每旋转一圈都会对故障部位产生冲击,形成明显的周期性冲击响应,基于此,可根据故障部位的响应周期对频谱添加冲击,即可得到故障数据。

通过对轴承故障机理分析,可知:①外圈故障有明显的外圈故障频率 F_{OR} ;②内圈故障有明显的内圈故障频率 F_{IR} ,还受到工频 F_r 的调制,可能出现 $F_{IR} \pm (t)F_r$;③滚动体故障有明显的滚动体故障频率 F_B ,同时 F_B 还受到 F_r 和保持架故障频率 F_{FT} 的调制,可能出现 $F_B \pm (t)F_r, F_B \pm (t)F_{FT}$ 。此外,会存在以上主要故障频率的倍频及边带。

依据经验:①各倍频及边带强度依次递减,本文衰减系数 α 取 0.65,边带阶数 $t = \{1, 2, 3\}$;②真实故障数据中理论故障频率与实际故障频率并不一致,在理论故障频率上下浮动一值作为预测的故障频率,该值取值参考频率分辨率以及各故障频率间的差异。

机械振动往往伴随调制现象,相比传统信号处理方法需要选择合适的频带进行带通滤波,本文方法依据专家经验选择 2 kHz 的高通滤波,采用图 7 所示流程对振动信号监测数据进行预处理得到频域数据作为迁移特征。




图 7 振动数据预处理流程

Fig.7 Preprocessing flow of vibration data

(2) 个性特征空间重构

预处理后振动信号的表达为

$$F_{re} = \sum_{i=0}^{N/2} C_i \times \delta \times (i \times f_0) + f_{res} \tag{4}$$

式中: N 为采样点数; f_0 为频率分辨率; C_i 为频率 $i \times f_0$ 的成分系数; δ 为激励函数; f_{res} 为设备残振。

其中: Nf_0, δ 可依据预处理流程直接得到; 而 C_i, f_{res} 是反映设备状态的关键参数; C_i 为各迁移特征分量的大小; f_{res} 与设备个性特征有关。对于本文方法中需要获取的设备个性特征空间,即设备健康状态,通过“2.2.2”节的 GAN 学习获得 $C_i f_{res}$ 。

(3) 训练样本生成

以 CWRU 轴承数据为例叙述故障特征集计算过程。由表 3 知有内圈故障、外圈故障和滚动体故障,故障种类 n 取 3; 采样点 N 取 12 288, 特征维度 m 为 $(N/2 + 1)$, 由式(2)得,其故障特征集如式(5)所示

$$H = [H_{OR} \ H_{IR} \ H_B]^T \tag{5}$$

对于外圈故障,其故障响应周期为 $\frac{1}{F_{OR}}$,则

$$H_{OR} = \begin{cases} h_{1-F_{OR}} = qP + C_{F_{OR}} \\ h_{1-2 \times F_{OR}} = \alpha qP + C_{2 \times F_{OR}} \\ h_{1-3 \times F_{OR}} = \alpha^2 qP + C_{3 \times F_{OR}} \\ P = E(F_{re}) \times \beta \end{cases} \quad (6)$$

式中: $h_{1-F_{OR}}$ 、 $h_{1-2 \times F_{OR}}$ 、 $h_{1-3 \times F_{OR}}$ 分别为外圈故障频率 1~3 倍频; P 为倍频系数; 以 F_{re} 幅值期望为基准并乘系数 β ; β 用于减轻实际中各种随机因素的影响,其值采样于 0~2 均值为 1、标准差为 0.33 的高斯分布; q 为衡量冲击响应的强度,为突出故障特征,依据“3 σ ”原则和量级差异, q 在 3~100 按均匀分布采样取值; α 取值参见“3.2.1”节中 1 所述。

同理可得 H_{IR} 、 H_B ,需要注意的是:对于轴承故障机理中所提及的可能出现的 F_r 和 F_{FT} 成分,其 P 需乘 0~1 间均匀分布的系数。

对于试验台模拟故障数据,有内圈、外圈两种故障和健康状态数据,采样点数定为 16 384,可采用相同方法得到故障特征集。

3.2.2 诊断模型训练及应用验证

对于 CWRU 轴承数据,采用 Li 等的方法进行重采样,以 N_0、N_3 数据为已知数据,并结合迁移特征集得到训练样本,每类状态包含 1 024 个样本,训练图 5 的诊断模型。对表 3 中的 36 种故障数据和两种健康数据(N_1、N_2)以 64 为重采样间隔得到测试样本。

对于试验台模拟故障数据,则以 138 个健康状态样本为已知数据,建立 3 种状态均包含 512 个样本的训练样本训练诊断模型,对表 4 所列 3 种状态的其余数据进行测试。

3.3 结果及分析

本文方法对两种实验数据的测试结果分别如表 5、表 6 所示。

表 5 本文方法对 CWRU 轴承数据的诊断准确率

Tab.5 The diagnostic accuracy of CWRU bearing data with MCGM

故障尺寸/mm	负载/kW	IR/%	OR/%	B/%
0	0	—	—	—
	0.745 7	—	100	—
	1.491 4	—	100	—
	2.237 1	—	—	—
0.177 8	0	100	100	100
	0.745 7	100	100	100
	1.491 4	100	100	100
	2.237 1	100	100	100
0.355 6	0	100	0	100
	0.745 7	100	0	100
	1.491 4	55.05	0	100
	2.237 1	98.27	0	100
0.533 4	0	100	100	57.98
	0.745 7	100	100	78.88
	1.491 4	100	100	78.25
	2.237 1	100	100	31.62
平均准确率			84.21	

万方数据

表 6 本文方法对试验台模拟故障数据的诊断准确率

Tab.6 The diagnostic accuracy of test bench's simulated fault data with MCGM

fault data with MCGM			%
健康	内圈故障	外圈故障	
100	100	100	

3.3.1 诊断效果分析

从表 5、表 6 可知,本文方法对 CWRU 轴承数据的平均诊断准确率超过 84%,对试验台模拟故障数据的诊断准确率达到 100%,详细的分析如下:① 通过观察大量实验数据的包络频谱,发现本文方法的诊断能力优于人工,如图 8 为 B07_0 故障数据采用图 7 流程得到的包络频谱,若人眼判断易被 166 Hz 内圈故障频率干扰,但本文方法依旧得到了准确诊断结论,且辨识时间在毫秒内;② OR14 故障的诊断准确率明显低于其他实验数据,如图 9 为 OR14_0 故障数据包络频谱,可看出杂频带较多,这一特征常见于滚动体故障,同时存在明显的 165 Hz 的内圈故障频率及倍频,推测是外圈中度故障引起滚动体故障和内圈故障导致,此时已为复合故障状态,但故障标记时只将其标记为外圈故障,B21 故障诊断准确率低的原因与此类似。




图 8 B07_0 故障数据包络频谱

Fig.8 Time-domain envelope waveform of B07_0




图 9 OR14_0 故障数据包络频谱

Fig.9 Time-domain envelope waveform of OR14_0

图 8 和图 9 两者相似度很高,但是轴承的故障原因不同,一方面受限于图 7 的预处理,另一方面则与故障机理尚不清晰有关,正如王国彪等提到缺乏故障机理等基础研究是现有故障诊断面临的首要问题。

3.3.2 变工况迁移性能分析

将本文方法与 Li 等、刘海宁等的方法进行对比分析,鉴于对 Li 等方法的考虑,CWRU 轴承数据中仅对健康状态数据和故障尺寸为 0.177 8 mm 的 3 种故障数据进行实验。对比方法对两种实验数据的诊断准确率见表 7、表 8,表 7 中,使用斜线格数据作为所在列方法的训练样本,表 8 中,每种工况均取 138 组数据作为训练样本。

表 7 对比方法在部分 CWRU 轴承数据的诊断准确率
Tab.7 The diagnostic accuracy of CWRU bearings with other algorithms

故障尺寸/mm	负载/kW	Li 等			刘海宁等		
		IR/%	OR/%	B/%	IR/%	OR/%	B/%
0	0	—	—	—	—	—	—
	0.745 7	100	100	100	100	100	100
	1.491 4	100	100	100	100	100	100
	2.237 1	100	100	100	100	100	100
0.177 8	0	—	—	—	—	—	—
	0.745 7	100	100	39.50	96.81	99.62	98.15
	1.491 4	100	100	73.63	95.67	96.86	99.41
	2.237 1	100	100	98.13	97.46	99.70	98.19
平均准确率		92.61			98.49		

表 8 对比方法在试验台模拟故障数据的诊断准确率
Tab.8 The diagnostic accuracy of test bench's simulated fault data with other algorithms

方法	Li 等			刘海宁等		
	健康	内圈故障	外圈故障	健康	内圈故障	外圈故障
准确率/%	100	100	100	100	97.37	98.23

对比表 7 和表 5,本文方法在变负载工况下的诊断准确率高于 Li 等和刘海宁等的方法。对比 Li 等的研究,虽然两者均基于 LeNet-5 构建诊断模型,但 Li 等直接采用时域数据作为输入导致其对频率信息不够敏感,在负载变化过程中,对干扰频率较多的滚动体故障的诊断精度不高;对比刘海宁等的研究,其通过计算人工提取特征的距离判别故障类型,距离判别方法无法衡量每个特征的权重,会受部分极值的影响,在两种实验数据上的诊断准确率均低于本文方法。此外,从表 5 可知,本文方法用两种健康状态数据实现了表 3 中其余 76.32% 工况的有效诊断(准确率大于 95% 为有效诊断),高于刘海宁等研究中提及的结果。

以上结果表明本文方法具备很好的变负载工况迁移能力。这源于本文方法依据故障机理选择合适的迁移特征并利用其分布规律生成故障数据,使得基于此数据训练的诊断模型能够区分该类状态。

3.3.3 实际应用可行性分析

Li 等和刘海宁等的方法均需故障数据作为样本,但在实际应用中,往往无法得到满足要求的故障数据,本文方法可直接应用于零故障样本条件下。从表 5、表 6,分别对比表 7、表 8 可知,本文方法诊断准确率优于

万方数据

Li 等和刘海宁等的方法,若有故障数据,将其与基于 MCGM 技术生成的样本混合作为训练样本,将有利于诊断准确率的提升。

从图 10 实验台模拟内圈故障数据包络频谱可知,实际内圈故障频率为 140.62 Hz,与 155.32 Hz 的理论故障频率相差很大。但本文方法对内圈故障数据的诊断准确率为 100%,该结果表明本文方法对频率偏移现象表现很好,一方面得益于 MCGM 中依据经验考虑了理论与实际的偏差;另一方面与诊断模型学习到各故障频率的分布规律,而不仅仅是频率值有关。




图 10 实验台模拟内圈故障数据包络频谱

Fig. 10 Time-domain envelope waveform of test bench's simulated inner ring fault

4 结 论

(1) 分析现有基于数据驱动的智能诊断方法面临的问题,提出采用生成样本训练诊断模型的方法,用于实现无故障数据样本条件下的智能诊断模型构建。实验结果表明,在滚动轴承上有很好的效果,优于单纯依据故障机理的人工诊断。

(2) 提出了基于 MCGM 样本生成方法。该方法可用于解决样本空间不完备的问题,增强数据学习效果。对当前机器学习中面临的小样本问题具有很强的指导意义和参考价值。

(3) 通过实验分析了基于特征的迁移诊断方法。在训练样本中加入故障特征后进行模型的学习,结果表明,在迁移工况下取得了较好的结果,可提高智能诊断模型的泛化性能,解决实际应用中领域间的偏移问题。

参 考 文 献

[1] JIA F, LEI Y, LIN J, et al. Deep neural networks: a promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data [J]. Mechanical Systems & Signal Processing, 2016, 72/73: 303–315.

[2] LI C, CHEN Y, ZHANG W, et al. A deep convolutional neural network with new training methods for bearing fault diagnosis under noisy environment and different working load [J]. Mechanical Systems & Signal Processing, 2018, 100: 439–453.

[3] JANSSENS O, SLAVKOVIKJ V, VERVISCH B, et al.

- Convolutional neural network based fault detection for rotating machinery[J]. *Journal of Sound and Vibration*, 2016, 377(1): 331–345.
- [4] 沈长青, 汤盛浩, 江星星, 等. 独立自适应学习率优化深度信念网络在轴承故障诊断中的应用研究[J]. *机械工程学报*, 2019, 55(7): 81–88.
- SHEN Changqing, TANG Shenghao, JIANG Xingxing, et al. Bearings fault diagnosis based on improved deep belief network by self-individual adaptive learning rate[J]. *Journal of Mechanical and Engineering*, 2019, 55(7): 81–88.
- [5] 李松柏, 康子剑, 陶洁. 基于信息融合及堆栈降噪自编码的齿轮故障诊断[J]. *振动与冲击*, 2019, 38(5): 216–221.
- LI Songbai, KANG Zijian, TAO Jie. Gear fault diagnosis based on information fusion and stacked de-noising auto-encoder[J]. *Journal of Vibration and Shock*, 2019, 38(5): 216–221.
- [6] 陈超, 沈飞, 严如强. 改进 LSSVM 迁移学习方法的轴承故障诊断[J]. *仪器仪表学报*, 2017, 38(1): 33–40.
- CHEN Chao, SHEN Fei, YAN Ruqiang. Enhanced least squares support vector machine-based transfer learning strategy for bearing fault diagnosis[J]. *Chinese Journal of Scientific Instrument*, 2017, 38(1): 33–40.
- [7] LU W, LIANG B, CHENG Y, et al. Deep model based domain adaptation for fault diagnosis[J]. *IEEE Transactions on Industrial Electronics*, 2017, 64(3): 2296–2305.
- [8] 刘海宁, 宋方臻, 窦仁杰, 等. 小数据条件下基于测地流核函数的域自适应故障诊断方法研究[J]. *振动与冲击*, 2018, 37(18): 36–42.
- LIU Haining, SONG Fangzhen, DOU Renjie, et al. Domain adaptive fault diagnosis based on the geodesic flow kernel under small data condition[J]. *Journal of Vibration and Shock*, 2018, 37(18): 36–42.
- [9] SONG W, XIANG J, ZHONG Y. A simulation model based fault diagnosis method for bearings[J]. *Journal of Intelligent & Fuzzy Systems*, 2018, 34(6): 3857–3867.
- [10] ZHANG M, WANG D, LU W N, et al. A deep transfer model with wasserstein distance guided multi-adversarial networks for bearing fault diagnosis under different working conditions[J]. *IEEE Access*, 2019, 7: 65303–65318.
- [11] 雷亚国, 杨彬, 杜兆钧, 等. 大数据下机械装备故障的深度迁移诊断方法[J]. *机械工程学报*, 2019, 55(7): 1–8.
- LEI Yaguo, YANG Bin, DU Zhaojun, et al. Deep transfer diagnosis method for machinery in big data era[J]. *Journal of Mechanical and Engineering*, 2019, 55(7): 1–8.
- [12] 王国彪, 何正嘉, 陈雪峰, 等. 机械故障诊断基础研究“何去何从”[J]. *机械工程学报*, 2013, 49(1): 63–72.
- WANG Guobiao, HE Zhengjia, CHEN Xuefeng, et al. Basic research on machinery fault diagnosis: what is the prescription[J]. *Journal of Mechanical and Engineering*, 2013, 49(1): 63–72.
- [13] 康守强, 胡明武, 王玉静, 等. 基于特征迁移学习的变工况下滚动轴承故障诊断方法[J]. *中国电机工程学报*, 2019, 39(3): 764–772.
- KANG Shouqiang, HU Mingwu, WANG Yujing, et al. Fault diagnosis method of a rolling rearing under variable working conditions based on feature transfer learning[J]. *Proceeding of the CSEE*, 2019, 39(3): 764–772.
- [14] 马波, 高金吉, 江志农. 基于专家思维的多维度故障诊断方法[J]. *机械工程学报*, 2017, 53(23): 32–38.
- MA Bo, GAO Jinji, JIANG Zhinong. Multi-dimensional fault diagnosis method based on expert thinking[J]. *Journal of Mechanical and Engineering*, 2017, 53(23): 32–38.
- [15] 尚宇炜, 马钊, 彭晨阳, 等. 内嵌专业知识和经验的机器学习方法探索(一): 引导学习的提出与理论基础[J]. *中国电机工程学报*, 2017, 37(19): 5560–5571.
- SHANG Yuwei, MA Zhao, PENG Chenyang, et al. Study of a novel machine learning method embedding expertise part I: proposals and fundamentals of guiding learning [J]. *Proceedings of the CSEE*, 2017, 37(19): 5560–5571.
- [16] 孙秋野, 胡旌伟, 杨凌霄, 等. 基于 GAN 技术的自能源混合建模与参数辨识方法[J]. *自动化学报*, 2018, 44(5): 901–914.
- SUN Qiuye, HU Jingwei, YANG Lingxiao, et al. We-energy hybrid modeling and parameter identification with GAN technology[J]. *Acta Automatica Sinica*, 2018, 44(5): 901–914.
- [17] ZHENG Z, ZHENG L, YANG Y. Unlabeled samples generated by GAN improve the person re-identification baseline in vitro [C]//*Proceedings of 2017 IEEE International Conference on Computer Vision*. Los Alamitos: IEEE, 2017.
- [18] 王坤峰, 左旺孟, 谭营, 等. 生成式对抗网络: 从生成数据到创造智能[J]. *自动化学报*, 2018, 44(5): 769–774.
- WANG Kunfeng, ZUO Wangmeng, TAN Ying, et al. Generative adversarial networks: from generating data to creating intelligence[J]. *Acta Automatica Sinica*, 2018, 44(5): 769–774.
- [19] ZHANG B, LI W, HAO J, et al. Adversarial adaptive 1D convolutional neural networks for bearing fault diagnosis under varying working condition[J]. *Electrical Engineering and Systems Science*, 2018, 3: 1–19.
- [20] GOODFELLOW I, JEAN P A, MEHDI M, et al. Generative adversarial nets[C]//*Proceedings of the 27th International Conference on Neural Information*. [S.l.]: ICNI, 2014.
- [21] ALEC R, LUKE M, SOUMITH C. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. *Computer Science*, 2015, 2: 1–16.
- [22] MIRZA M, OSINDERO S. Conditional generative adversarial nets [EB/OL]. arXiv preprint arXiv: 1411. 1784, 2014. <https://arxiv.org/abs/1411.1784>, 2014.
- [23] SMITH W A, RANDALL R B. Rolling element bearing diagnostics using the case western reserve university data: a benchmark study [J]. *Mechanical Systems & Signal Processing*, 2015, 64/65: 100–131.
- [24] 胡爱军, 赵军, 孙尚飞, 等. 基于相关峭度共振解调的滚动轴承复合故障特征分离方法[J]. *振动与冲击*, 2019, 38(8): 110–116.
- HU Aijun, ZHAO Jun, SUN Shangfei, et al. A compound fault feature separation method of rolling bearing based on correlation kurtosis resonance demodulation[J]. *Journal of Vibration and Shock*, 2019, 38(8): 110–116.